

Hierarchical Framework of interaction-aware Motion Prediction for Autonomous Car

감상 논문

한양대학교 ERICA 기계공학과 4학년 공민수

Minsu Kong (2020077792)

초 록

해당 논문은 Data-driven method와 model-driven method를 계층적으로 사용하여 surrounding vehicles에 대한 trajectory를 예측하는 내용을 담고 있다. 본 논문에서 언급하고 있는 학습된 AI는 복잡한 상호작용 환경에 대한 모델링을 해소시켜주며 임의의 입력에 대해 SV의 ‘행동’ 예측값을 출력해준다. 이를 기반으로 HD map이 제공하는 도로 정보를 통해 안전한 경로를 생성하고 MPC를 통해 시간에 따른 속도를 profile을 산출한다. 이러한 계층적 시스템 구조를 통해 주변 차량의 행동, 경로, 속도까지 통합적으로 예측함으로써 ego vehicle이 충돌을 회피할 수 있는 사전 대응 판단에 기여할 수 있음을 보였다.

이에 자율주행 자동차의 판단 및 제어를 희망하는 본인은 해당 논문을 분석해보며 전체적인 시스템 흐름을 파악해보려고 한다.

0. 용어 정리

Hierarchical: 계층적인

Maneuver: 움직임

Frenet coordinate: 곡선 기반 좌표계

Interaction-aware: 상호작용 + 의도 고려

Trajectory: 시간에 따른 위치, 속도, 방향 (궤적)

Dynamic environment: 차간 거리, 속도 보행자 등

Prediction horizon: 예측 시간 구간

Cornor case: 특이 케이스

Lane association: 차선 번호, 차선 중심부터 거리

Track history: 과거 주행 궤적 데이터

Ground truth: 현실에서 실제로 측정된 정답 데이터
(예측 정확도 평가와 모델 학습에 필요함)

1. 선행 연구

자차의 충돌 예방 trajectory를 계획하기 위해서는 주변 차량의 trajectory를 예측하는 것이 필요하다. 따라서 motion prediction에 관한 연구가 필요하다. Motion prediction에 대한 방법론은 Pyhsics 기반, Maneuver 기반, Interaction-aware기반으로 이루어져 있으며 interaction_aware기반을 통한 motion prediction은 정확도와 신뢰성 그리고 더욱 긴 예측 시간이 가능하다. Figure 1을 살펴보면 Physics-based model의 경우 CV로 판단된 자동차는 계속 CV일 것으로 예측한다. 이는 간단한 움직임 예측에는 적용 가능하지만 도로나 주변 환경에 대한 상호작용을 하지 않는 한계점이 있다. Maneuver-based model의 경우 좌회전을 한다는 행동 기반을 통해 예측된다. 이는 좌회전 깜빡이를 통해 인식될 수 있다. 하지만 이 또한 주변 환경과의 상호작용을 하지 못하는 경우를 보였다. 그에 반해 Interaction-aware model는 갈색과 파란색 차가 서로 움직임의 의도를 예측하며 파란차는 정지 후 좌회전을 하는 것을 볼 수 있다.

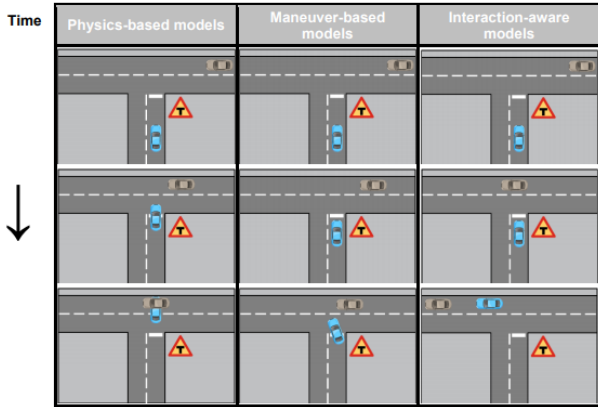


Figure 1 Example of motion prediction results by each model

이러한 Interaction-aware model을 해당 논문에서는 Data-driven prediction과 Model-driven prediction으로 나누어 접근하고 있다.

1.1 Data driven motion prediction

딥러닝 학습 모델을 사용함으로써 복잡한 시나리오에 강인한 판단이 가능하다. 전통적인 예측 방법은 짧은 예측 시간과 간단한 시나리오에 사용하기 적합했으며 이는 AI의 중요성을 보여준다.

딥러닝 모델 중 RNN의 경우 시간에 따른 변화를 파악하여 과거 움직임의 흐름을 통해 패턴을 예측하는 것이다. CNN의 경우는 카메라 센서처리에 많이 사용되며 이미지를 분석하여 차선, 차간거리 등 공간적 특징을 파악하는데 사용된다.

딥러닝 모델의 장점은 복잡한 수학적 모델링과 수학적 최적화 과정이 필요하지 않고 빠르게 실시간 판단이 가능하다. 그에 반해 방대한 양의 데이터 학습이 필요하고 물리적 제약조건에 대한 안전성이 떨어지고 특히 훈련되지 않은 특이 케이스에 대한 대처가 부족하다는 단점을 가지고 있다.

1.2 Model driven motion prediction

모델 기반 모션 예측은 물리적 모델 기반을 통해 많은 연구가 되어왔지만 주변 상황과의 상호작용을 고려하기 어렵다는 한계점이 있다. 따라서 교통 주행 상호작용을 고려한 수학적 모델인 planning based prediction이 설계되었다.

이는 먼저 주변 상황을 수학적으로 모델링하고, 이 모델을 기반으로 미래 궤적을 계획하며, 그 결과를 예측으로 사용하는 방법이다.

해당 논문은 LSTM기반 예측된 행동과 HD map을 기반으로 오일러 큐빅 스플라인을 최적화해서 경로를 생성하고 있다. 이러한 경로는 ego vehicle에게 주변 차량의 움직임 예측에 기반이 될 것이다. 이러한 방식은 물리적 제약조건을 고려한 최적화된 예측이 가능하고 방대한 데이터가 요구되지 않는다는 점에서 Data driven motion prediction과 대비된다. 그러나 수학적 모델의 복잡성과 많은 컴퓨팅 자원을 요구한다는 것이 단점이다.

2. System Architecture

Data-driven maneuver prediction(DMP)와 Model-driven trajectory prediction(MTP)의 단계적 과정을 통해 최종적으로 TV의 움직임이 예측된다.

차량의 상태(X, Y, 2D_SIZE, V)와 HD map(road geometry)가 필요하다.

DMP단계에서는 데이터의 좌표계를 카타시안에서 Frenet 좌표계로 변환하고 LSTM 딥러닝 모델을 활용하여 TV의 행동(LK, LLC, RLC)을 예측한다.

MTP단계에서는 예측된 행동과 도로의 곡률, 물리적 제약조건을 기반으로 Path를 생성하고 MPC방법을 사용하여 speed profile을 생성한다.

3. Data driven maneuver prediction

행동을 예측하기 위해서는 어떤 feature를 사용할 지와 모델을 어떻게 디자인할 건지 결정해야 한다. 이 논문에서는 SV와 TV의 횡/종방향 거리, 절대 속도, 2D Size를 고려하였으며, 특히 TV가 주행 중인 도로 곡률도 함께 활용하였다.

행동 예측은 LSTM 기반 분류 모델로 수행되며 예측 행동은 LK, LCC, RCC로 구분된다. 입력 사이즈를 고정하기 위해 인접 차량이 부족할 경우 가상의 자동차를 추가하여 항상 6개의 주변 차량에 대한 입력벡터를 유지시켰다.

또한 좌표계는 카타시안 좌표계를 frenet 좌표계로 변환을 하였으며 이는 corner case를 방지하고 road geometry와 lane association을 직관적으로 반영하기 위함이다.

4. Model driven trajectory prediction

LSTM모델을 통해 행동을 예측한 이후 이 행동에 대한 trajectory를 예측해야 한다. 이는 path와 speed profile로 나뉘어 진행된다.

4.1 Lateral motion prediction based on cubic spiral

차량이 시작 지점에서 끝지점까지 차량이 추종하기 적합한 경로를 생성하기 위해서 곡률의 연속성이 중요하다. 이를 만족시키기 위해 곡률함수를 cubic polynomial로 모델링하였다. 3차 다항식의 4개의 미정계수를 결정하기 위해 설정한 3가지 조건은 다음과 같다.

1. 시작과 끝점의 위치, 방향, 곡률정보
2. 곡률에 물리적 제약 조건 추가
3. 곡률을 고르게 분포

1번의 경우 시작점은 현재상태의 TV로 구해질 수 있고 끝점의 경우 예측된 행동과 HD map을 통해 얻을 수 있다.

2번의 경우 차량의 구심가속도 한계에 따라 곡률의 최대값을 정할 수 있으며 논문에서는 1/3, 2/3지점의 곡률에 제한 조건을 추가하였다.

3번의 경우 곱힘 에너지 식을 목적 함수로써 사용하며 이를 통해 곡률의 급격한 변화구간을 최소화한다.

최적화 변수로는 $k(0)$, $k(sf/3)$, $k(2sf/3)$, $k(sf)$ 지점에 대한 곡률 정보와 arc 길이 sf 를 활용하였으며 이 5개의 정보 중 시작점과 끝점을 제외한 3개의 변수를 최적화하였다. 이를 통해 4개의 미정계수는 3개의 변수로 표현된다.

4.2 Longitudinal motion prediction based on MPC

TV의 속도 프로파일을 예측하기 위해서는 고속도로 주행 상황을 고려해야 한다. 법적 제한 속도, 안전거리 유지, 곡선 구간 과속 주의와 같은 속도 제약 조건을 고려하여 논문에서는 Model Predictive Control 기반 방법을 사용하여 최적 속도 프로파일을 생성하였다. TV의 상태를 기반으로 상태모델, 목적함수, 동적 제약조건이

설계되었고 이를 통해 최적 제어 입력을 계산한다. 목적함수는 추종 오차와 제어입력 제어입력의 변화량 제곱에 가중치를 곱한 합이며 일정한 time horizon에서의 최소값을 통해 최적화가 가능하다. MPC 모델은 TV와 Preceding vehicle관계를 통해 두 가지 시나리오로 나뉜다.

1. Speed Keeping (SK): 앞차가 없을 때, 규제 속도 및 곡률 제한에 따라 목표 속도(v_{ref})를 유지.
2. Car Following (CF): 앞차가 있을 때, 안전거리를 유지하며 주행.

SK 모델에서는 목표 속도를 도로 규제 속도와 곡률 기반 최대 속도 중 작은 값으로 설정한다. 추종 오차는 목표 속도와 예측속도의 차로 정의하며, 제어 입력은 가속도이다. SK 모델에서는 가속도가 일정한 MPC 모델로 표현 가능하며 이때 TV의 상태는 v 뿐이다.

CF 모델에서는 TV의 상태는 앞차 간의 거리 차와 속도 차로 사용된다. 추종 오차는 안전거리와 앞차 간의 거리의 차로 정의하며, 제어 입력은 가속도이다. 이때 제어 행렬이 요소가 음수인 이유는 가속도가 증가하면 거리와 속도 차가 감소하기 때문이다.

5. Experiments

5.1 평가 요소 및 데이터 활용

DMP + MTP의 성능 평가를 위해 다음과 같은 3가지 평가 요소를 제시하였다.

1. RMSE
2. ADE
3. FDE

1번의 경우 예측값과 ground truth값의 제곱 오차 평균의 루트를 나타내며 2번의 경우 전체 예측 기간 동안에 예측값과 ground truth값의 거리 오차를 나타낸다. 3번의 경우 최종 위치에 대한 예측값과 ground truth값의 거리 오차를 나타낸다. ground truth 값은 NGSIM dataset을 사용하며 데이터 일부는 Table 1과 같다.

Vehicle_ID	Frame_ID	Total_Frames	Global_Time	Local_X	Local_Y
2	13	437	1.11885E+12	16.467	35.381
2	14	437	1.11885E+12	16.447	39.381
2	15	437	1.11885E+12	16.426	43.381
2	16	437	1.11885E+12	16.405	47.38
2	17	437	1.11885E+12	16.385	51.381
2	18	437	1.11885E+12	16.364	55.381
2	19	437	1.11885E+12	16.344	59.381

Table 1 Example of motion prediction results by each model

데이터에서 vehicle ID, Frame_ID, Local_X, Local_Y, v_length, v_width, v_vel, preceeding 과 같은 시계열 데이터를 확인해 볼 수 있었다.

해당 알고리즘을 사용하기 위해서는 HD map이 필요함으로 본 논문에서는 NGSIM 데이터를 통해 HD map을 만들었다. 이는 데이터 내에 도로의 곡률 정보가 포함되어 있지 않아 그런 것으로 판단된다. HD map을 만드는 과정은 다음과 같다.

1. 모든 차량의 Trajectory data를 축적한다.
2. 각 라인 별로 0.1m단위로 구분한다.
3. 구분된 구역을 각각 평균 포인트를 계산한다.
4. 이 포인트들을 필터링과 이후 spline을 사용하여 HD map을 완성한다.

5.2 결과

본 논문에서는 다른 모델 예측 기법 대비 5초 예측 정확도가 56% 향상되었음을 보였으며 이를 통해 interaction_aware 기반을 통한 motion prediction의 긴 예측 시간 특성을 더욱 향상시킨 것을 알 수 있었다.

그리고 (LK, SK), (LK, CF), (LC, SK), (LC, CF) 4가지 주행 상황에 대한 시각 자료를 통해서 path prediction과 trajectory prediction의 차이를 직관적으로 확인할 수 있었다. 기존에는 path 예측은 주행 효율성 및 안정성을 고려하여 계산된 정적 경로일 뿐이며 이를 속도 프로파일과 결합하여 최종 trajectory를 예측한다는 것과 같이 개념적으로만 알고 있었다. 이를 Figure 2의 (b), (d)상황을 통해 path prediction과 trajectory prediction의 차이를 명확히 확인할 수 있어 이해에 도움이 되었다.

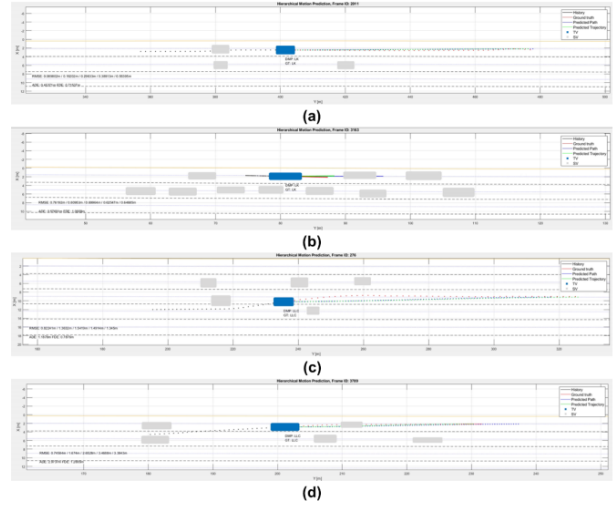


Figure 2 Example of motion prediction results by each model

6. Conclusion

1. 본 논문은 TV의 SV들의 상호작용을 고려하여 TV의 모션 예측을 하는 방법론에 대해 다룬다.
2. DMP는 복잡한 상황 속에서도 수학적 모델링 없이 TV의 행동을 예측 가능하며 LC, LLC, RLC로 분류된 행동을 기준으로 최소 96.3%의 정확도를 보여주었다.
3. MTP는 최적 trajectory를 예측하며 이는 spiral path와 speed profile의 결합을 통해 생성 가능하다.
4. 기존 motion prediction 대비 더 긴 시간 예측에 대한 강인함을 보였다.

7. Reflections

개인 프로젝트로 로봇의 localization을 구현하면서 자율주행에 관심을 가지게 되었고 판단 제어 분야에 대한 진로희망을 품고 본 논문을 접했습니다. 생소한 내용들이 많고 깊게 이해하지 못한 개념들이 아직 많지만 논문을 분석하면서 전체적인 시스템 자체가 흥미롭게 느껴졌던 시간이었습니다. 읽어 주셔서 감사합니다.

8. Reference

Y. Na, Hierarchical Framework of Interaction-aware Motion Prediction for Autonomous Car, M.S. thesis, Dept. of Smart Vehicle Engineering, Graduate School of Konkuk University, Seoul, South Korea, 2021.